

# Sparse-view 3DGS 패러다임 선택 연구 — 요약본

퍼지컬 AI 환경의 자율주행 로봇 온디바이스 공간 인지를 위한 Sparse-view 3D Gaussian Splatting 패러다임 선택 조건 분석  
KCI 논문 | 3인 공동 (이용수·황인재·서창희) | 목표 제출 2026년 10~11월 | H200 × 1

## 0. 한 문장

"사진이 적고 시간이 없을 때, 3D를 만드는 두 방식 중 어느 쪽을 써야 하는가 — 그리고 언제 '더 다듬는 것'이 오히려 해가 되는가."

## 1. 출발점 — 이동 로봇이 낯선 공간에 들어섰을 때

실내를 주행하는 로봇이 새 구역에 진입하면 세 가지 제약이 동시에 걸린다.

- 프레임이 적다** — 멈춰서 수십 장 찍는 게 아니라 통과하며 얻은 몇 장이 전부
- 겹침이 불규칙하다** — 직선 구간은 많이 겹치지만 코너에서 급감
- 연산 시간이 고정돼 있다** — 온디바이스라 허용 지연이 하드웨어·태스크로 미리 정해짐

이 세 제약이 그대로 본 연구의 세 통제 축이다. 즉 **계산 예산은 학습 변수가 아니라 배치 환경이 결정하는 값**이며, 이 축을 넣은 것 자체가 응용을 전제한 설계다.

## 2. 두 방식과 흔들리는 통념

|    | Feed-forward (학습형)                      | Per-scene optimization (개별 최적화형)   |
|----|-----------------------------------------|------------------------------------|
| 쉽게 | 많이 배운 전문가가 <b>한눈에 보고 즉답</b>             | 매 현장에서 <b>시행착오로 다듬어 완성</b>         |
| 동작 | 사전학습 네트워크가 단일 forward pass로 Gaussian 출력 | 초기 point cloud에서 시작해 렌더링 오차를 반복 갱신 |
| 시간 | 초 단위 이하                                 | 수십 초 ~ 수십 분                        |
| 약점 | 학습 분포 밖 장면에서 저하                         | 입력이 희소하면 <b>잘못된 형상에 과적합</b>        |

통념은 "느리지만 정확한 optimization"이었다. 그런데 최근 보고가 이를 흔든다 — ReSplat은 8-view에서 per-scene 3DGS가 과적합으로 무너져 feed-forward가 앞선다고 했고, Diff3R은 sparse 세팅의 test-time optimization(TTO)에서 **품질이 오히려 떨어지는 사례**를 보고했다(MVSplat -0.005dB, AnySplat -0.216dB). SplatFormer는 그 과적합의 형태를 서술한다 — 입력 시점에만 맞는 **길쭉한(elongated) Gaussian**이 생기고 표면 커버리지가 성겨진다.

**남은 공백** — 이 현상들은 개별 method 논문의 부수적 관측으로만 존재한다. 입력 희소성·겹침·계산 예산을 **동일 프로토콜에서 통제해 경계를 매핑한 연구는 없다**.

## 3. 연구 질문

입력 view 수, view overlap, 계산 시간 예산에 따라 두 패러다임의 품질-효율 우위는 어떻게 변화하며, 그 역전 경계는 무엇이 결정하는가?

본 논문은 method paper가 아니라 **Empirical Study + Controlled Analysis + Failure Analysis**를 결합한 분석 논문이다.

## 4. 서사 사슬

Regime Map (현상: 어디서 갈리는가)  
↓ "왜 갈리는가?"  
기하 프록시 + 최적화 동역학 (증거)  
↓ "정말 그 원인인가?"  
Depth noise 개입 + Refinement On/Off (통제)  
↓ "그래서 어떻게 하라는 것인가?"  
Confidence 기반 예산 결정 + Practical Guideline (처방)

## 5. 기여

### C1-a. 품질-시간 Regime Map

view 수 × overlap × 계산 예산에서 대표 시스템들의 실용적 승패 영역을 매핑하고 품질-시간 Pareto frontier를 병기한다.

★ **프레이밍 전환** — 지도의 색을 "누가 이겼는가"가 아니라 **refinement 이득의 부호(양 / 0 / 음)**로 칠한다. "A가 B보다 낫다"보다 "**시간을 더 쓰면 오히려 나빠지는 조건이 존재한다**"가 반직관적이고 실무적으로 결정적이다. 실험은 동일하고 해석 축만 바뀐다.

### C1-b. 동일 초기값 Refinement On/Off

동일한 feed-forward 출력을 초기값으로 고정한 뒤 refinement를 off(0초)/on(10·60·300초)으로 비교한다. 모델 요인(학습 데이터·크기·구현 최적화)이 상수로 묶이므로 "**최적화라는 행위 자체**"의 순효과가 분리된다.

쉽게: 출발점을 똑같이 맞춰 놓고 다듬기만 컸다 컸다 하며 그 효과를 잴다.

**전제 조건** — FF Gaussian을 표준 3DGS 표현으로 변환할 때 렌더 결과가 동일해야 한다(등가성 gate). 통과 못 하면 진행하지 않는다. 변환 오차가 refinement 효과로 오인되기 때문이다.

### C2. 기하 불확실성-렌더링 실패 연결 (논문의 심장)

사전 가설 세 개를 파일럿 전에 동결한다.

| 가설 | 내용                                                                                      | 성격                     |
|----|-----------------------------------------------------------------------------------------|------------------------|
| H1 | 초기 geometry 오차 $\uparrow \rightarrow$ Gaussian 수는 늘지만 held-out 품질은 감소, low-overlap에서 강화 | 통제 개입 $\rightarrow$ 인과 |
| H2 | view 수 $\downarrow \rightarrow$ 품질 정점 시점이 앞당겨지고 정점 후 하강이 가팔라짐                           | 관찰 $\rightarrow$ 메커니즘  |
| H3 | 초기 geometry가 충분히 정확하면 refinement 한계 이득이 소멸                                              | 통제 개입 $\rightarrow$ 인과 |

**개입 방법** — 초기 3D point 생성에 쓰인 depth를 두 방식으로 교란. ① iid 오차  $d' = d(1+\epsilon), \epsilon \sim N(0, \sigma^2), \sigma = 0/0.01/0.03/0.05/0.10$  ② 전역 스케일 편향  $d' = s \cdot d, s = 0.9 \sim 1.1$ .

C4-a. ★ Training-free 예산 결정 신호 (신규)

모델이 자체 출력하는 confidence만으로, refinement에 예산을 쓸지 말지를 추론 시점에 판정할 수 있는가?

Diff3R은 per-Gaussian uncertainty를 학습해서 얻는다(implicit gradient + 재학습 필요). 그러나 기성 feed-forward 모델은 이미 per-pixel confidence를 출력한다(DepthSplat의 depth 신뢰도, VGGT/DUST3R 계열의 confidence map). 이를 장면 단위로 집계한 값이 refinement 이득의 부호를 예측하는지 검증한다.

성립하면 주장은 이렇다 — "경계 판정에 별도 학습이 필요 없다. 기성 모델의 confidence에 이미 신호가 들어 있다."

쉽게: 로봇이 3D를 다듬기 전에, 모델이 스스로 매긴 자신감 점수만 보고 "이 장면은 더 다듬어봐야 소용없다"를 판단할 수 있는지 보는 것.

- 추가 실험 비용 0 — FF 추론 시 confidence를 함께 로깅하면 되고, 라벨은 C1-b 결과가 제공
- 온디바이스 앵커와 정합 — 연산을 쓰기 전에 쓸 가치를 판단하는 문제
- 위험 관리 — MVSplat은 cost volume 기반이라 명시적 confidence가 없을 수 있음. 없으면 매칭 비용 분포  $\cdot$  depth 분산을 대체 신호로 사용하고, 그것도 불가하면 DepthSplat 단독 보고로 축소

C4-b. Practical Guideline

분석 결과를 조건별 선택 규칙표로 요약한다(추가 실험 없이 결과에서 파생).

C3. 경량 Paradigm Selector (여유 시)

co-visibility  $\cdot$  texture 통계  $\cdot$  geometry confidence 기반 승자 예측. scene 단위 group split 필수. 일정 압박 시 가장 먼저 분리.

6. 실험 설계 요약

**공정성 원칙 ①** — 모든 방법에 동일한 카메라 pose 제공(pose 품질 비교로 오염 차단). Pose-free는 후속 분리. **공정성 원칙 ②** — 시스템 간 성능차에는 모델 요인이 섞이므로 C1-a는 "대표 시스템의 실용적 우위"까지만 주장. 패러다임 진술은 C1-b에만 근거.

| 통제 축    | 수준                              | 근거                              |
|---------|---------------------------------|---------------------------------|
| View 수  | 2 / 4 / 8 / 12 (모델 지원 미달 시 축소)  | 주행 중 확보 가능한 키프레임 수              |
| Overlap | 고 / 저 (co-visibility 수치 구간)     | 직선 구간 vs 코너 진입                  |
| 계산 예산   | 1 / 10 / 60 / 300초 (end-to-end) | 즉시 반응 / 정지 처리 / 작업 준비 / 오프라인 갱신 |

**비교군** — FF 2종(DepthSplat, MVSplat) + Optimization 2종(vanilla 3DGS, sparse 특화 1종) + C1-b 트랙 + 초기화 ablation(COLMAP vs VGGT/DA3).

**핵심 프로토콜 (사전 확정 12항목 중)** - 시간 경계 — 방법별 초기화 시간까지 포함한 end-to-end가 메인 - **예산 시점 선택** — 예산 종료 시점 체크포인트만 사용. test PSNR 최고점 사후 선택 금지(**test leakage**). oracle peak는 별도 보고 - **Overlap** —  $O_{ij} = 2|P_i \cap P_j| / (|P_i| + |P_j|)$ , 매칭 실패 쌍은 제외가 아니라 **0으로 포함**(제외 시 low-overlap에서 과대평가), 집계는 평균+하위 25%, view 수 내 총화 - **통계** — 독립 단위는 run이 아니라 **scene**. cluster bootstrap CI + 장면별 win rate - **지표** — PSNR/SSIM/LPIPS + **PCC**(GT 없이 기하 붕괴 측정) + **Gaussian 이방성**(길쭉함 정도) + DTU 전용 floater  $\cdot$  Chamfer

**규모** — 장면 20~30개, seed 3회, 실사용 200~300 GPU-hour.

7. 선행 연구 대비 위치

| 이미 보고된 것                  | 출처                      | 본 연구가 규명하는 것               |
|---------------------------|-------------------------|----------------------------|
| 저overlap에서 pixel 기반 FF 붕괴 | Omni-Scene (CVPR 2025)  | 경계가 어디인지, 동일 데이터셋 내 통제 축으로 |
| per-scene이 입력 시점에 과적합     | SplatFormer (ICLR 2025) | 입력 희소성에 따라 언제 시작되는지 궤적 정량화 |
| TTO 이득이 0/음수인 사례          | Diff3R (2026)           | 세 축 전면에서 부호 지도로 매핑         |
| 예산-품질 트레이드오프              | ForeSplat (2026)        | 단일 패러다임 내부가 아닌 패러다임 간 비교로  |
| COLMAP vs VGGT 초기화 비교     | 방송미디어공학회 (국내)           | 인용·확인. 우리 조건 축에서의 확장       |

8. 어떤 결과가 나와도 성립하는 이유

| 결과         | 기여                       |
|------------|--------------------------|
| 역전이 선명함    | regime map 자체            |
| 특정 조건에만 존재 | "보고된 역전의 조건 한정"          |
| 역전이 없음     | 통념 확증 + Pareto + 실패 메커니즘 |

세 경우 모두 **C2(원인 분석)**와 **C4-a(무료 판정 신호)**는 독립적으로 성립한다.

9. 후속 확장

**regime-aware hybrid** — 입력 조건과 예산을 보고 refinement 수행 여부·범위를 결정하는 선택적 최적화. C4-a가 그 판정 신호의 실현 가능성을 미리 검증하는 셈이다. 석사 과정 method 논문으로 연결.

부록. 용어

| 용어                      | 설명                                            |
|-------------------------|-----------------------------------------------|
| 3DGS                    | 3차원 공간에 반투명 타원 알갱이 수십만 개를 배치해 장면을 표현하는 기법     |
| Sparse-view             | 입력 사진이 몇 장뿐인 상황                               |
| Feed-forward            | 사전학습 신경망이 한 번의 순전파로 3D를 출력하는 방식               |
| Per-scene optimization  | 장면마다 처음부터 반복 최적화하는 방식                         |
| Refinement / TTO        | 주어진 초기값에서 추가 최적화하는 것 (test-time optimization) |
| 과적합 (overfitting)       | 가진 사진에만 지나치게 맞춰 새 시점에서 오히려 나빠지는 현상            |
| Overlap (co-visibility) | 두 시점이 같은 3D 지점을 함께 보는 정도                      |
| Densification           | 최적화 중 Gaussian을 분할·복제해 늘리는 과정                 |
| Confidence              | 모델이 자기 예측의 신뢰도를 스스로 매긴 값                      |
| PCC                     | 렌더링 depth와 기준 depth의 상관계수. 스케일 불변 기하 지표       |
| 이방성 (anisotropy)        | Gaussian이 얼마나 길쭉한지. 과적합의 형태학적 징후              |
| Held-out                | 학습·최적화에 쓰지 않고 평가용으로 남긴 시점                     |
| Test leakage            | 평가 데이터를 보고 결과를 고르는 것                          |
| Cluster bootstrap       | 상관된 표본을 장면 단위로 묶어 신뢰구간을 구하는 방법                |